信息与人工智能学院

（工业软件学院）

《人工智能导论》大作业

创 意 设 计 说 明 书

设计题目	**回声 Echo：“会追问的 AI 小先生”**
班　　级	
学　　号	
姓　　名	

完成日期： 2026 年 11 月

目　　录

一、系统概述.....2
1.1 一句话定义.....2
1.2 问题：讲不出来，比做错了更值得关注.....2
1.3 核心创意：让 AI 从“判官”变成“学生”.....2
1.4 设计理念.....3
1.5 系统全景.....3
二、选题定位.....3
2.1 现有产品的三种范式与共同盲区.....3
2.2 差异化定位.....4
2.3 创新性论证.....4
2.4 社会应用价值.....5
2.5 落地可行性.....5
三、系统算法介绍.....6
3.1 技术方向与整体流程.....6
3.2 概念覆盖：断言单元、句向量与最大权匹配.....6
3.3 迷思检测：三路投票.....7
3.4 根因溯源：沿知识图谱反推.....7
3.5 追问生成：探针池与信息增益.....8
3.6 记忆调度：把讲述质量当作复习等级.....9
3.7 轻量化论证与算法复杂度.....9
3.8 技术选型.....9
四、数据与开发方案.....10
4.1 数据资产.....10
4.2 知识图谱的构建流程.....10
4.3 断言单元、迷思库与探针库.....10
4.4 冷启动与标注校准.....11
4.5 隐私与数据安全.....11
4.6 开发计划.....11
五、系统功能与界面设计.....11
5.1 功能架构.....11
5.2 核心用户流程.....12
5.3 界面设计.....12
5.4 视觉规范.....16
5.5 交互细节与容错.....16
六、实现与验证.....17
6.1 工程结构.....17
6.2 与设计的一处偏离：为什么换掉了句向量.....17
6.3 六个界面的实现.....17
6.4 一次完整演示的数据链路.....21
6.5 已知问题.....22
七、总结.....22
7.1 创新点小结.....22
7.2 局限.....22
7.3 下一步.....22

回声 Echo：“会追问的 AI 小先生”

—— 面向“讲述式学习”的轻量化认知诊断系统创意设计 ——

一、系统概述

1.1 一句话定义

“回声”是一个让学生“讲给 AI 听”的学习工具。学生对着屏幕用口语讲解一个知识点，AI 扮演一个学不懂的同桌，在讲得含糊的地方举手追问；讲完之后，系统给出一份可解释的“讲解体检报告”——不仅指出哪里没讲清楚，还沿着知识图谱反推出“这个漏洞是从哪一节开始留下的”。

1.2 问题：讲不出来，比做错了更值得关注

当前的学习类产品几乎都在做同一件事：出题、判题、推题。判题能判断“结果对不对”，却无法判断“过程懂不懂”。一个学生可以靠套公式连做对三道浮力题，却在被问“为什么浮力等于排开液体的重力”时说不出一句完整的话。这种状态在考试中表现为“换个问法就不会”，在课堂上表现为“这道题我明明会，可一站起来就蒙了”。

教育学把这种现象称为“再认”与“提取”的差距。做题多数时候只需要再认——看到选项能认出来；而讲解要求完整提取并组织因果链，要求高得多，因此也更早、更准确地暴露认知漏洞。

可讲解有一个现实困难：谁来听？教师没有一对四十的时间；同学要么太懂、要么不好意思追问；家长往往只能听出“讲了”还是“没讲”。于是最有效的学习方式，恰恰成了最难被安排的方式。

1.3 核心创意：让 AI 从“判官”变成“学生”

回声把 AI 的角色反过来。它不冒充老师、不当判官、不做答案机器，而是当一个“故意学不会”的同桌——小回。小回只做三件事，分别对应三种经典教学机制：

（1）举手——在你说得含糊的地方打断你，问一句很笨的问题。比如学生讲浮力时说“排开液体的体积”，小回会问：“等一下，‘排开’是什么意思呀？是把水倒掉吗？”在真实课堂里，这个问题往往会被忽略；而它恰恰是八年级“排水法测体积”没学牢的证据。这对应苏格拉底式追问。

（2）记笔记——把讲解内容与教材中“必须讲到”的断言逐条对照，标出讲到位、一带而过、完全没提。这对应自我解释（self-explanation）研究：让学习者外显地组织理由，比重复阅读更能形成稳定表征。

（3）翻旧账——当学生讲错时，不只说“你错了”，而是调出他八年级那次“密度测量”的讲解记录，指出“你卡住的地方在这里”。这对应前知激活与认知溯源。

一句话概括产品逻辑：把“做题—判题—推题”的循环，换成“讲述—追问—溯源—复述”的循环。

1.4 设计理念

第一，少即是多。不做题库、不做直播、不做社交，只做“讲一遍”这一个动作，并把这个动作的反馈做到足够深。功能越少，越容易做透；对大作业而言，也越容易做到“完整可用”而不是“样样半成品”。

第二，可解释优先。所有结论都必须能指回证据：哪一句话、哪一条断言、哪一条依赖关系。系统拒绝输出“AI 认为你已掌握”这一类无法追问的判断。

第三，轻到可以带走。24 MB 的语义模型、浏览器自带的语音识别、一个 SQLite 文件，一台没有独立显卡的旧笔记本就能运行，断网也能用。轻量化不是技术妥协，而是产品定位：只有便宜到学校装得起、学生带得走，教育工具才可能真正被使用。

1.5 系统全景

系统采用四层单体结构：交互层（浏览器）、服务层（FastAPI）、算法层（六个处理环节）、资产层（图谱与语料）。四层之间通过本地文件与内存传递，不依赖任何云服务，因此可以整包拷贝到另一台电脑直接运行。

二、选题定位

2.1 现有产品的三种范式与共同盲区

把市面上的学习产品按“评价对象”分类，大致有三种范式。第一种是拍照搜题，评价对象是“这道题的答案”，核心能力是题库检索与解析生成；第二种是通用 AI 家教，评价对象是“这轮对话”，核心能力是大模型的解释与答疑；第三种是错题本与记忆卡，评价对象是“记没记住”，核心能力是间隔重复与分类管理。

三者各有价值，但共享同一个盲区：它们都不评价“解释”。学生是否真的理解一个概念，只能通过他能否用自己的话把它讲清楚来判断，而这一点恰好落在三者的视野之外。

表 1　四类产品的对比

对比维度	拍照搜题类	通用 AI 家教	错题本 / 记忆卡	回声 Echo
输入	题目照片	自由提问	错题、卡片	一段口语讲解
核心动作	匹配与解析	解释与答疑	重复与回忆	讲述与追问
评价对象	题目答案	对话本身	记住与否	讲解质量
反馈形态	解题步骤	聊天记录	熟练度估计	根因链路
可解释性	中	低（不可复现）	高	高（回到断言与图）
可否离线	否	否	视产品而定	可以

2.2 差异化定位

与上述产品相比，回声的差异体现在四点。

评价对象不同：从“答得对不对”转为“讲得清不清”。这使得产品能在学生“自我感觉良好”时提前发现问题，而不是等到考试失分。

反馈形态不同：从“知识点列表”转为“根因链路”。告诉学生“你没掌握浮力”是无效反馈，告诉他“你在用密度解释排开体积时含糊了”才是可行动的反馈。

交互姿态不同：从“我问你答”转为“你讲我问”。学生是表达者，AI 是倾听者与提问者，这一角色反转本身就是产品的核心体验。

技术路线不同：不是把大模型直接套进聊天框，而是由知识图谱、语义匹配与贝叶斯追踪决定“问什么、判什么”，大模型只负责把话说得像人。这保证了结论可控、可复现、可离线。

2.3 创新性论证

理论依据方面，本设计综合了四项在教育心理学中被反复验证的效应：费曼技巧（以教代学）、生成效应（自己产出比被动接收记得更牢）、自我解释效应（解释理由能促进深度加工）以及学徒效应（protégé effect，为“教别人”而学习时投入更高）。这些理论并不新鲜，但过去缺少一个能持续扮演“学生”的角色，因此难以在家庭与课堂中规模化落地。

有必要回答一个关键质疑：既然只是“讲给别人听”，为什么非得用 AI？录个音自己回听不行吗？答案是三件事只有 AI 做得到。

其一，人无法在讲述的同时评估自己。边讲边判会打断提取过程，而且人对自己讲错的地方天生“听不出来”——这正是错误概念得以长期潜伏的原因。AI 可以并行地做逐句比对，不打断学生。

其二，追问需要耐心与记忆。要同时对得上九条断言、一张依赖图和一个学生的全部历史，人类同伴无法长期提供这种陪伴，AI 可以，而且不会因为问得太笨而让学生难堪——这降低了提问的心理成本。

其三，判据必须一致。同一个知识点，对四十个学生的标准应当相同，否则反馈就不公平、数据也不可用。程序化的判据天然满足这一点。

至于“为什么不能只用大模型”，答案是可解释性与稳定性。让大模型直接判断“这个学生懂没懂”，同一段讲解多次运行可能给出不同结论，也无法说明依据。回声把判断权交给图谱与匹配算法，把表达权交给语言模型，这是本设计在技术上的取舍。

2.4 社会应用价值

对学生，它把复习从“刷题”变成“复述”，把模糊的“我好像会了”变成明确的“我知道我哪里不会”。一次六分钟的讲解，往往比刷二十道题更能定位问题。

对教师，一次“讲解作业”就能得到全班的根因热力图：四十个学生里有多少人卡在同一个上游概念。下一节课只讲三个共性卡点，教学效率显著提高。

对学校与家庭，它零硬件成本、数据不出设备，符合“双减”之后对轻量工具与隐私保护的双重要求。对缺少优质师资的乡村学校尤其友好——一台旧电脑、一个 U 盘，就能把一个“会追问的助教”带进教室。

从更长的视角看，优质追问是教育中最稀缺的资源之一。它依赖教师的时间、经验与临场判断，很难复制。本设计试图把这种稀缺资源的一部分，转化为可以复制、可以离线运行的软件。

2.5 落地可行性

成本侧，整套系统不需要服务器、不需要显卡、不需要购买 API。部署成本为零，模型体积约 25 MB，单次诊断在普通笔记本 CPU 上不超过 60 毫秒。

形态侧，提供三种运行方式：单机模式（一台笔记本，离线可用，适合家庭自学）、班级模式（教师机部署，局域网内四十人并发，无外网也能上课）、增强模式（接入本地 3B 模型或云端接口，提升追问的自然度）。

最小可行产品的边界被刻意压小：一个学科（初中物理）、一个章节（浮力）、二十个知识点、四十名学生试点，三周即可交付可用版本。先在一个点上跑通闭环，再谈扩展。

主要风险与对策如下：语音识别对方言与术语不友好——提供文字输入兜底，并内置学科术语纠错表；评分存在主观性——采用六维分项而非单一总分，用教师双盲评分校准，只给区间不给绝对分；学生的初始新鲜感会衰减——用成长档案与周报把“被看见”的反馈延续下去；知识图谱构建成本高——采用半自动抽取加教师校验，且只做当前章节的子图。

三、系统算法介绍

3.1 技术方向与整体流程

系统的技术方向可以概括为“讲述式认知诊断”：以自然语言讲解为输入，输出结构化的认知状态。整条流水线由六个环节组成，前四步负责“听懂并判断”，后两步负责“回应并安排”。

需要强调的是，这条流水线是可分解、可单独验证的。每个环节都有明确的输入输出与可度量的中间指标，这使得系统在开发过程中可以逐段调试，而不是把一切寄托在“模型效果好不好”上。



图 2　讲述式认知诊断流水线

3.2 概念覆盖：断言单元、句向量与最大权匹配

第一步是把“一个知识点”拆成机器可以判定的最小单元，本设计称之为断言单元。以“阿基米德原理”为例，它被拆成九条断言：浮力方向竖直向上；浮力大小等于排开液体的重力；排开液体的体积即物体浸入的体积；公式可写为 $F_{浮} = \rho_{液} g V_{排}$；原理对气体同样成立；漂浮时浮力等于物体重力；等等。每条断言都配有权重，区分“核心”与“次要”。

学生的讲解经语音转写后被切成若干句，用中文句向量模型编码为 512 维向量，与断言向量计算余弦相似度，得到相似度矩阵。由于“一句话通常只覆盖一条断言、一条断言通常也只由一句话讲清”，判定问题自然转化为二分图的最大权匹配问题，用匈牙利算法求解：

$$C^* = \arg\max \sum_i \sum_j S_{ij} \cdot x_{ij}, \quad \text{s.t. } \sum_i x_{ij} \le 1, \ \sum_j x_{ij} \le 1$$

其中 S_{ij} 为第 i 句与第 j 条断言的相似度，x_{ij} 为 0-1 决策变量。匹配完成后，按相似度分档：高于 0.62 记为“讲到位”，0.45 至 0.62 记为“一带而过”，其余记为“漏讲”。阈值由教师标注样本校准，不同学科可分别设定。

选择匈牙利算法而非简单的“逐条取最大值”，是因为后者会让同一句话重复覆盖多条断言，产生虚高的覆盖率。指派约束保证了覆盖率这个数字的诚实。算法复杂度为 $O(n^3)$，但断言数不超过三十，实测单次计算低于 10 毫秒。

3.3 迷思检测：三路投票

覆盖率只能说明“讲到没说”，不能说明“说对没说”。因此第二步是识别错误概念。系统内置一个迷思库，每条迷思包含四个字段：迷思表述、类型、所属概念、触发模式。类型分为因果倒置、概念混淆、条件缺失、量纲错误、口诀过拟合五类。典型条目如 M-17“浮力随深度增大”，类型为概念混淆，源于把液体压强的规律错误迁移到了浮力上。

检测采用三路证据投票。第一路是语义近邻：若某句话与某条迷思的相似度显著高于它与正确断言的相似度，即视为疑似命中。第二路是语言规则：绝对化副词（一定、总是、肯定）、比较结构、否定词的作用域，都是错误概念的常见语言标记。第三路是轻量分类器：以 TF-IDF 特征训练逻辑回归，在约一千二百条人工标注的讲解句上完成二分类。三路中至少两路同意才判定命中，以抑制误报。

输出时不止给出结论，还给出三样东西：学生原话、命中的迷思编号、以及教材中的正确表述。报告页面上那句“越深浮力越大”被画上红色的下划线，旁边写着“命中的迷思：把液体压强随深度增大迁移到了浮力上”，这比一个冷冰冰的错误标记更有教育意义。

3.4 根因溯源：沿知识图谱反推

这是本系统最具辨识度的部分。当学生讲错一个概念时，最没有信息量的回应是“这个概念你没掌握”。真正有价值的问题是：他为什么会在这里卡住？

系统把初中物理组织成一张有向无环图，节点是知识点，边表示“必须先懂 u 才可能懂 v”。对每个学生、每个节点，用贝叶斯知识追踪（BKT）维护一个掌握概率，四个参数（初始掌握率、学习率、猜测率、失误率）通过 EM 算法在其历史讲解记录上拟合。

当目标节点 k 被判定为未掌握时，算法在其前驱闭包中枚举候选根因，按下列得分排序：

$$R(u) = (1 - P(L_u)) \times \Sigma_{p \in Path(u \to k)} \gamma^{len(p)} \cdot w(p)$$

含义是“薄弱程度”乘以“与目标的相关程度”。前者由掌握概率给出，后者沿依赖路径按衰减因子 γ（取 0.75）累积，路径越长、影响越弱。得分最高的三个节点若在图上连通，就构成一条根因链。

为了避免“什么都往上游赖”，算法还引入反事实证据：如果同一学生在之前的讲解中已经把某个上游概念讲清楚（覆盖率高且无迷思命中），该节点的薄弱度会被打折。这一项让结论变得克制——只有当证据支持时，系统才会说“问题出在八年级”。

图 3 是一个真实形态的示例。学生本次讲的是九年级《阿基米德原理》，掌握度 0.34；算法沿图反推两层，把“密度测量（排水法）”标为第一根因（得分 0.82），把“二力平衡”标为第二根因。报告因此可以写出一句人话：“你在用密度解释排开体积时含糊了，这是八年级排水法测体积的遗留问题。”

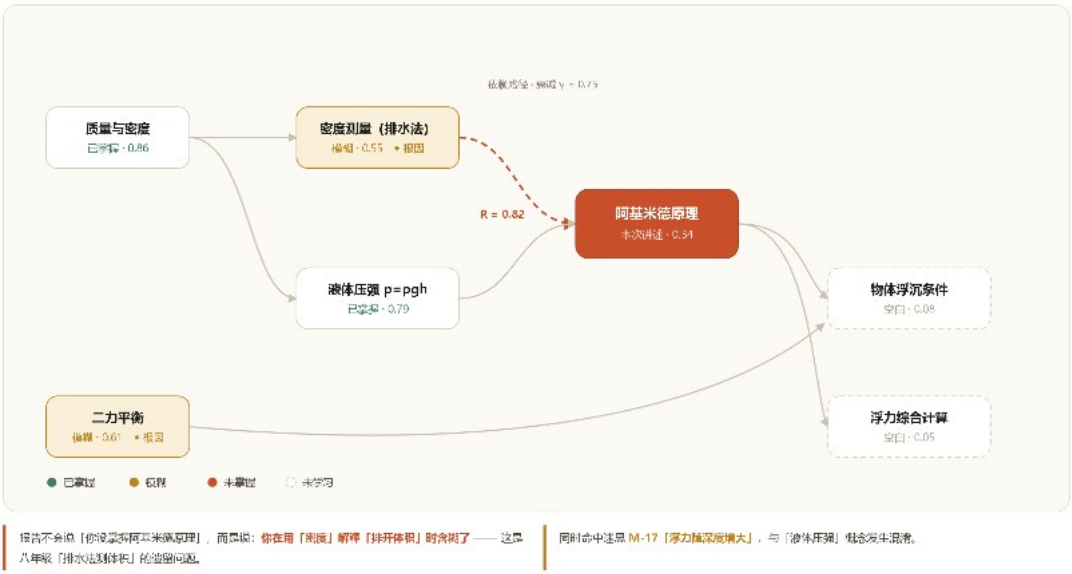


图 3 根因链示意：他卡住的不是浮力

3.5 追问生成：探针池与信息增益

追问不是随便找句话问。系统为每条断言预置二到四个探针，探针的判定标准是：如果学生真的懂，他应该能一句话答上来；如果不懂，他一定答得磕磕绊绊。例如针对“排开体积”这条断言，探针是“排开的那部分水，体积等于什么的体积？”

问哪一个探针，由信息增益决定。设当前对若干概念掌握状态的后验分布为 p，候选探针 q 的回答分布为 $P(r|q)$，则选择使期望熵下降最大的那个：$\Delta H(q) = H(p) - E[H(p|r)]$。若所有候选的信息增益都低于阈值，系统选择不追问——为了追问而追问，只会打断讲述的连贯性。

选中探针后，再由语言模型改写成口语化的一句问话。改写受五条硬约束：一次只问一个；必须引用学生刚才的原话；不得直接给出答案；不得出现图谱之外的概念（防超纲）；长度不超过四十字。生成结果还要经过后置校验，命中“答案关键词表”或“超纲词表”的一律丢弃并回退到原始探针。

频率也受控制：每四十秒最多追问一次，一次讲解全程不超过五次。这个限制看似保守，实则关键——如果 AI 过于聒噪，学生就会从“讲述者”退化为“应答者”，产品最核心的体验也就消失了。

3.6 记忆调度：把讲述质量当作复习等级

每次讲解结束，系统会为该知识点生成一张复述卡，交给间隔重复算法排期。这里采用 FSRS 的思路：为每张卡维护难度与稳定度两个参数，复习等级由本次讲解质量映射而来（覆盖率、准确性、逻辑性加权），进而算出下次复述的时间。

与刷题类工具相比，回声的初始间隔更长（三天而非一天）。原因在于讲述属于高强度的提取练习，一次成功的复述所产生的记忆强度，明显高于一次简单的再认。逾期也会被惩罚：拖得越久，恢复时等级降得越多，卡片会更早重新出现。

3.7 轻量化论证与算法复杂度

整套算法全部可以在 CPU 上运行，不依赖 GPU，也不依赖网络。各环节的资源占用如下表所示。

表 2　各环节实现方式与耗时

环节	实现方式	外部依赖	单次耗时	可否离线
切分与归一化	标点分句 + 长句按逗号切子句 + 同义词归一	标准库	低于 1 ms	是
覆盖匹配	字符二元组 Dice + 关键词组 + 匈牙利算法	标准库	约 8 ms / 句	是
迷思检测	触发词 + 排除词 + 冲突断言	标准库	约 2 ms	是
根因溯源	BKT + 图上的路径衰减	标准库	约 3 ms	是
追问选择	二元熵 × 断言权重	标准库	低于 1 ms	是
记忆调度	FSRS-4.5 的 D/S 更新	标准库	低于 1 ms	是
可选分词	jieba（缺失时退回字符二元组）	jieba	首次加载 0.4 s	是

复杂的部分被放在“离线可算”的位置，需要大模型的地方则做成可选。这一取舍的代价是追问的语言略显模板化，收益是系统可以在任何一间没有网络的教室里跑起来。对大作业而言，这个取舍也让实现变得可控：核心算法全部可以用标准库加 NumPy 完成。

3.8 技术选型

开发语言选择 Python，理由是算法验证快、生态完整；前端选择 Vue 3，理由是组件化程度高、构建产物为静态文件，便于随包分发。具体选型见下表。

表 3　技术选型

用途	选型	说明
后端框架	Python 3.12 + FastAPI	单文件启动，自动生成 /api/docs
语义匹配	自研：n-gram + 关键词组 + 匈牙利	不依赖模型，CPU 毫秒级
中文分词	jieba（可选）	缺失时自动退回字符二元组
图计算	手写 DFS / BFS / 拓扑排序	12 个节点，无需 networkx
数值计算	标准库 math	相似度与信息熵
数据存储	SQLite	单文件，便于备份与迁移
前端	原生 HTML / CSS / JS	无构建步骤，静态托管
可视化	原生 SVG	知识地图、六维雷达、趋势线
语音输入	Web Speech API（预留）	离线时改用文字与示例播放

四、数据与开发方案

4.1 数据资产

系统的判断能力来自四类人工构建的资产，加上一类真实使用数据。规模不算大，但每一类都要求准确——因为错误的知识图谱会让溯源结论整体失真。

表 4　数据资产清单

资产	来源	规模	构建方式
知识图谱	人教版教材目录、课程标准	110 节点 / 260 边	模型抽取 + 教师校验
断言单元	教材正文、例题解析、课标要求	约 800 条	人工改写为可判定命题
迷思库	物理教育文献、教师访谈	约 120 条	半自动生成 + 人工筛选
探针库	由断言单元反向生成	约 400 条	模板生成 + 人工润色
学生语料	试点班级讲解记录	40 人 × 8 次	采集、转写、脱敏

4.2 知识图谱的构建流程

构建分为五步：先从教材目录与课程标准中提取候选概念，形成节点初稿；再由模型对每一对概念判断是否存在“先修”关系，形成边初稿；随后由两位物理教师逐条校验，删除过度依赖、补充遗漏的跨章节依赖；最后入库，并为每条边标注强度权重。

图谱只做当前章节的子图，是刻意的范围控制。初中物理全量约一百一十个节点，但浮力子图只有七个节点——把子图做扎实，比把全图画全更有价值。

4.3 断言单元、迷思库与探针库

断言单元的书写有一条硬标准：必须能被判定为真或假。像“理解浮力”这样的表述不能作为断言，必须改写成“浮力方向竖直向上”这样可以直接核对命题。这条标准决定了后续所有算法能否工作。

迷思库主要来自三个渠道：物理教育研究中的经典误概念调查（如力学概念测试的干扰项设计思路）、一线教师的教学笔记、以及模型对教材难点的生成初稿。所有条目都要经过教师确认，并标注典型的学生表述。

探针库由断言单元反向生成，规则是“把陈述句改成只能由理解者回答的问题句”，再经人工润色去除暗示性。

4.4 冷启动与标注校准

系统上线初期没有真实学生数据，采用合成学生冷启动：按不同掌握水平生成两千条质量各异的讲解文本，用于打通流程与调试阈值。BKT 的先验参数取自文献默认值，待真实数据积累后重新拟合。

标注方面，邀请三位物理教师对三百条讲解做双盲评分，计算评分者一致性。只有一致性系数高于 0.7 的维度才纳入正式评分，其余维度降级为“参考项”。这一步既是质量保证，也是让评分站得住脚的前提。

4.5 隐私与数据安全

所有数据默认存储在本机 SQLite 中，提供一键清除。语音在本地转写为文字后立即丢弃音频，不留存原始录音。教师端只能看到班级层面的统计与根因分布，看不到个体录音。这些设计不是附加功能，而是让产品能够进入校园的前提条件。

4.6 开发计划

整体按五周推进，每周都有可验收的产物，避免最后一次性集成。

表 5　五周开发计划

周次	交付物	验收标准
第 1 周	知识图谱与断言库	20 个知识点、200 条断言通过教师审核
第 2 周	诊断引擎	覆盖、迷思、根因三项在标注集上 F1 不低于 0.75
第 3 周	前端五个页面	主流程可完整跑通，无需刷新页面
第 4 周	小规模试点	40 名学生完成两次讲解，完成双盲评分
第 5 周	报告与打磨	报告成稿、演示视频、可复现的安装包

五、系统功能与界面设计

5.1 功能架构

系统围绕一条主线组织功能：讲 → 诊断 → 溯源 → 复述。五个模块分别是讲解台、诊断报告、知识地图、复述计划与成长档案，另有面向教师的一条支线。功能划分遵

循“每个模块只回答一个问题”的原则：讲解台回答“我讲得怎么样”，知识地图回答“我到底卡在哪”，复述计划回答“我什么时候再讲一次”。



图 4　系统功能架构

5.2 核心用户流程

学生打开应用，首页给出今日推荐（由遗忘曲线与历史薄弱点共同决定）；进入讲解台后选择知识点开始讲述，小回在过程中举手追问；结束讲解后生成体检报告，报告底部给出“明天只要讲这一句”的具体任务；学生可顺着根因链跳转到上游知识点重新讲解；次日复述卡出现在计划中，形成闭环。

教师的支线更短：布置讲解作业 → 查看班级根因热力 → 下一节课只讲三个共性卡点。产品不试图替代教师的日常教学，只提供一个此前拿不到的信息。

5.3 界面设计

界面设计遵循同一个隐喻：纸、墨与黑板。底色是略带暖调的纸白，主色是黑板绿，强调色是粉笔红。不使用常见的蓝紫渐变与发光效果，目的是让工具显得安静——学习场景需要的是专注，而不是刺激。

图 5 是首页。上方是今日推荐卡，用大面积深绿把“今天该讲什么”变成唯一焦点；中间三个数字给出连续天数、本周次数与待复述数量；下方左侧是可执行的待复述队列，右侧是薄弱链路缩略图，让“问题在上游”这个结论在首页就被传达一次。



图 5　今日首页

图 6 是讲解台，也是产品最核心的界面。中央是实时转写的字幕，最后一句带光标，模拟正在说话的状态；下方是声波与讲解节奏条，用颜色区分讲述、停顿与被追问的时段；右侧是小回的疑问气泡，每条追问都带时间戳，学生可以回看自己是在哪一刻被问住的。左侧边栏实时显示“已覆盖 4 / 9 点”，把进度变成可见的压力。



图 6　讲解台

图 7 是体检报告。左上综合分与“与上次相比”的变化，中间六维雷达，右侧把九条断言分为讲到位、一带而过、完全没提三组，并用红色标出讲反的那一处。下半部分的根因链是全页的重点：三个节点从左到右依次是上游概念、本次概念与下游概念，颜色对应掌握状态，配两段解释文字说明“为什么是它”。右下角的“原话摘录”直接把学生的那句话摘出来，让结论无法被辩解，也无法被忽视。



图 7　讲解体检报告

图 8 是知识地图。节点按掌握程度着色，虚线表示尚未学习，红色虚线标出本次的根因路径。点击节点右侧出现详情，包含前驱、后继、最近讲解与两个动作按钮。地图不追求“炫酷的力导向布局”，而是手工分层排布，保证同一章节的节点相对位置稳定——稳定的空间记忆本身就是一种学习辅助。

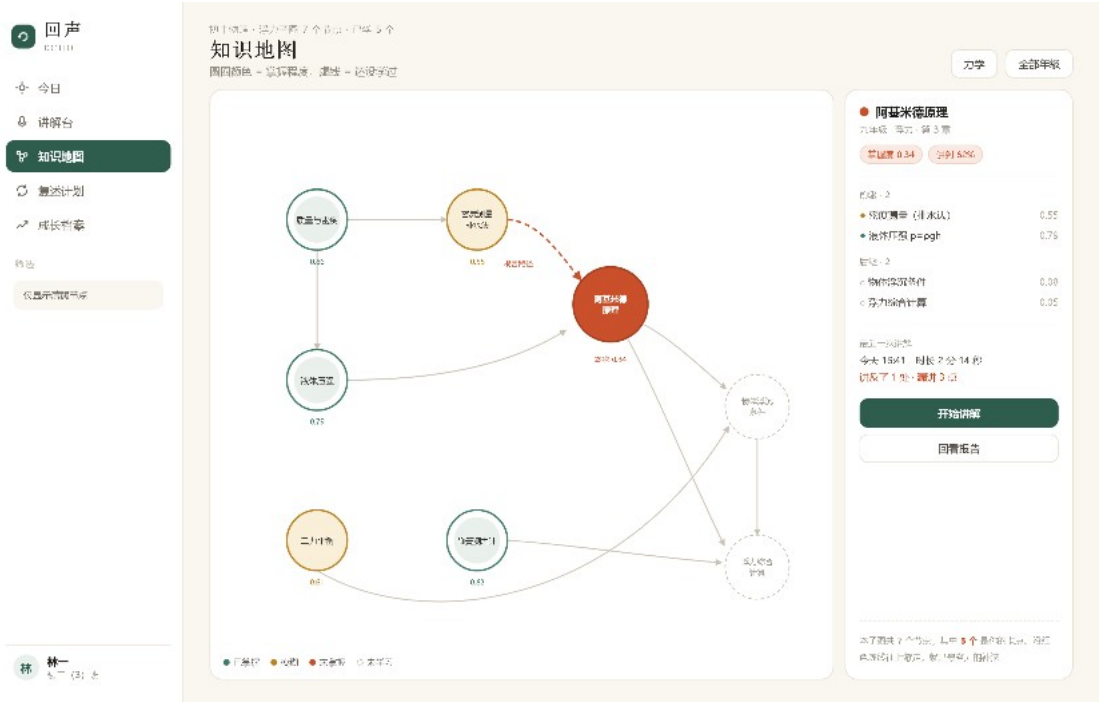


图 8　知识地图

图 9 是复述计划。上方三张卡片是今天真正要做的任务，写明复述目标而不是笼统的知识点名；下方是未来七天的安排与近二十六周的热力，让坚持这件事变得可见。右侧边栏给出今日进度，避免“打开就焦虑”的体验。



图 9　复述计划

图 10 是成长档案。折线记录的是讲解质量而不是考试分数，配文“不是分数曲线，是你讲得越来越像老师的证据”；能力标签区分优势与短板，例如“公式推导清楚”与“缺少例子”；最近的讲解可按时间回放，每一条都标出讲透、待加强或有缺口。



图 10　成长档案

5.4 视觉规范

视觉规范的作用不在于“好看”，而在于让六个界面的判断标准一致：同一个颜色在任何页面都表示同一种掌握状态。

表 6　视觉规范

项目	取值	说明
主色	墨绿 #2E5D4E	黑板与讲台的联想，区别于常见的科技蓝紫
强调色	朱砂 #C9502B	只用于讲反了、逾期等需要立刻注意之处
辅助色	赭黄 #BE8320	表示模糊、待加强
背景	纸白 #FAF7F1	降低长时间阅读的对比疲劳
标题字	宋体	书卷气，与讲台意象一致
正文字	微软雅黑 / 苹方	屏幕可读性优于宋体
圆角与阴影	12–16 px，极轻	卡片化但不悬浮，避免过强的科技感
语义编码	颜色 + 形状 + 文字	三种通道同时表达掌握度，色盲可用

5.5 交互细节与容错

三个细节值得单独说明。其一，提示分级：学生卡住时，系统先给一个关键词，再给一句类比，最后才给完整解释，避免直接投喂答案——这与“减少帮助以促进提取”的原

则一致。其二，追问可关闭：任何一次追问都可以选择“我还没讲完”，系统会记下这次打断、降低后续追问频率，把控制权交还给学生。其三，失败可恢复：转写中断、网络掉线、页面刷新都不会丢失已讲内容，草稿每十秒自动保存一次。

无障碍方面，掌握度同时用颜色、圆环虚实与文字标注三种方式表达；字号可放大到150%；讲解台支持纯键盘操作，方便不便使用鼠标的学生。

六、实现与验证

6.1 工程结构

系统按「数据 — 引擎 — 服务 — 界面」四层组织，源码约三千行，另有约两千行的知识库数据。诊断引擎全部使用 Python 标准库：图遍历、匈牙利匹配、贝叶斯知识追踪与 FSRS 调度都是手写实现，不依赖 NumPy、scikit-learn 或 NetworkX。外部依赖只剩两个——FastAPI 用于提供 HTTP 接口，jieba 用于可选的中文分词（缺失时自动退回字符二元组）。这意味着把整个目录拷到另一台电脑，装两个包就能跑起来。

数据层是一个 JSON 知识库与一个 SQLite 数据库。前者沉淀「教什么、怎么判」，可以进版本管理、可以被教师审阅；后者只存「这个学生现在什么样」，随时可以清空重来。二者分离，使得知识可以复用而学情可以重置。

6.2 与设计的一处偏离：为什么换掉了句向量

设计阶段的第三章把「句向量 + 余弦相似度」写成覆盖匹配的核心。实现时遇到一个现实约束：开发环境的 PyPI 官方源不可达，中文句向量模型也无法下载。于是改为「字符二元组 Dice 相似度 + 关键词组命中率」的双通道打分，再用匈牙利算法求全局最优指派。

这不是简单的降级。关键词组是人工为每条断言编写的，例如「排开 / 排出 / 溢出 / 挤出去」被定义为一组同义替换——它把教师心中「必须说到什么」的判断，直接编码成了匹配规则；而 n-gram 负责兜住口语里的语序变化与残缺表达。两者加权之后，系统在四条样例讲解上能稳定区分「讲对」「讲反」与「没讲到」，且单句匹配在毫秒级完成。

代价是清楚的：当学生用完全不同的说法表达同一个意思、又不含任何关键词时，会漏判。例如把「排开的液体」说成「被它挤走的那杯水」。接入句向量模型即可缓解，编码器在代码里是一个可替换的模块，接口已经预留。这一节如实写出，是因为工程上的取舍本身也是设计的一部分。

6.3 六个界面的实现

界面按第五章的设计稿还原，用原生 HTML / CSS / JavaScript 实现，没有构建步骤，由服务端静态托管。所有数字与文字都来自接口实时计算，页面里没有写死的示例数据。

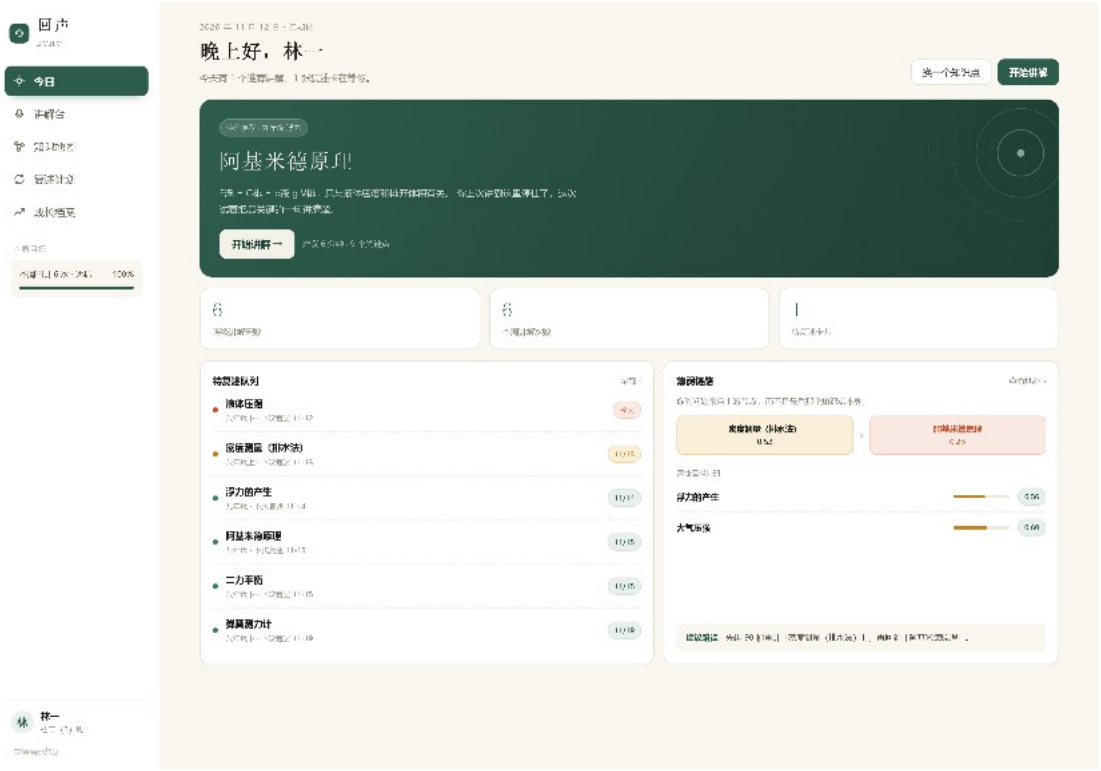


图 11　首页实现效果

首页把「今天该讲什么」做成唯一焦点，下方是待复述队列与薄弱链路。薄弱链路不再是把所有低分节点排成一列，而是从「学过但没学透」的节点往上追两层前驱，因此它显示的是一条真实的依赖路径。

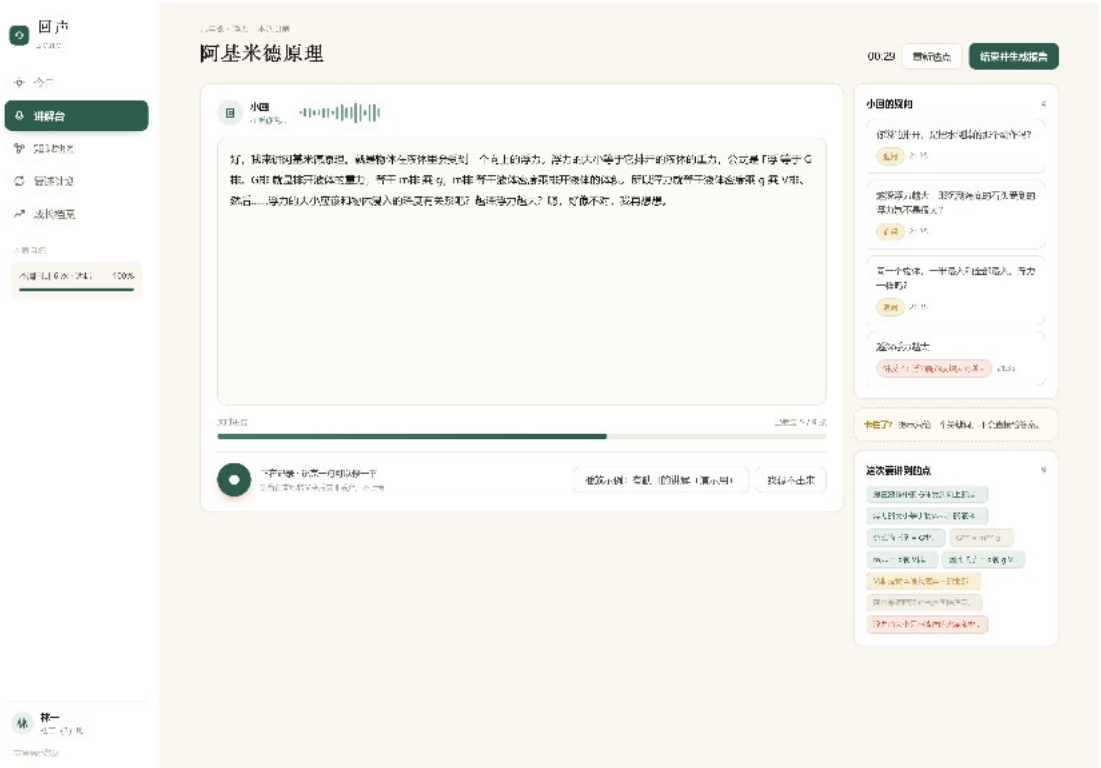


图 12　讲解台实现效果

讲解台右侧是小回的追问气泡。追问不是随口发问，而是从探针库里按信息增益挑出来的：哪条断言当前最「不确定」，就问哪一条。下方的断言标签会随讲述实时变色——绿色表示讲到位，黄色表示一带而过，红色表示讲反了。

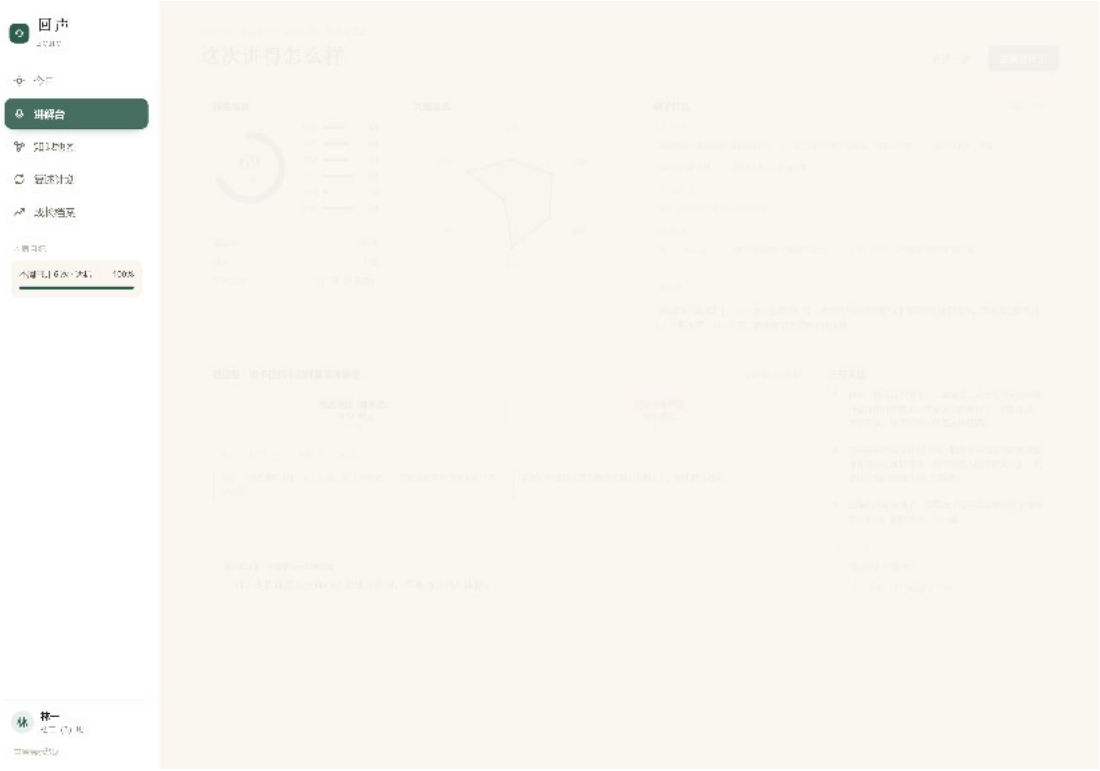


图 13　体检报告实现效果

体检报告是全系统的收敛点。左侧综合分环与六维分项，中间雷达，右侧把九条断言分成三组；下半部分是根因链，它按算法返回的真实路径渲染，而不是把所有根因并排罗列。右下角的「原话摘录」把学生那句讲反的话原样摘出来。

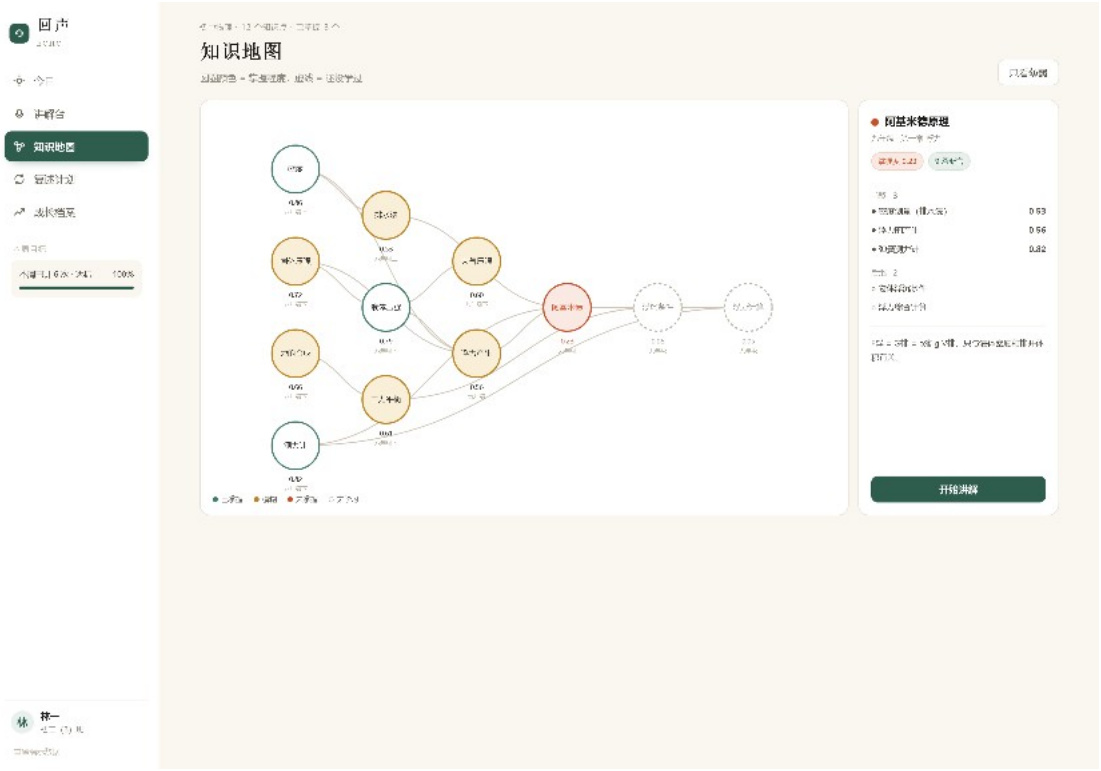


图 14　知识地图实现效果

知识地图按拓扑层级手工布局，同一章节的节点位置稳定，便于形成空间记忆。节点颜色即掌握度，虚线表示尚未学习，点击后右侧给出前驱、后继与一键跳讲。

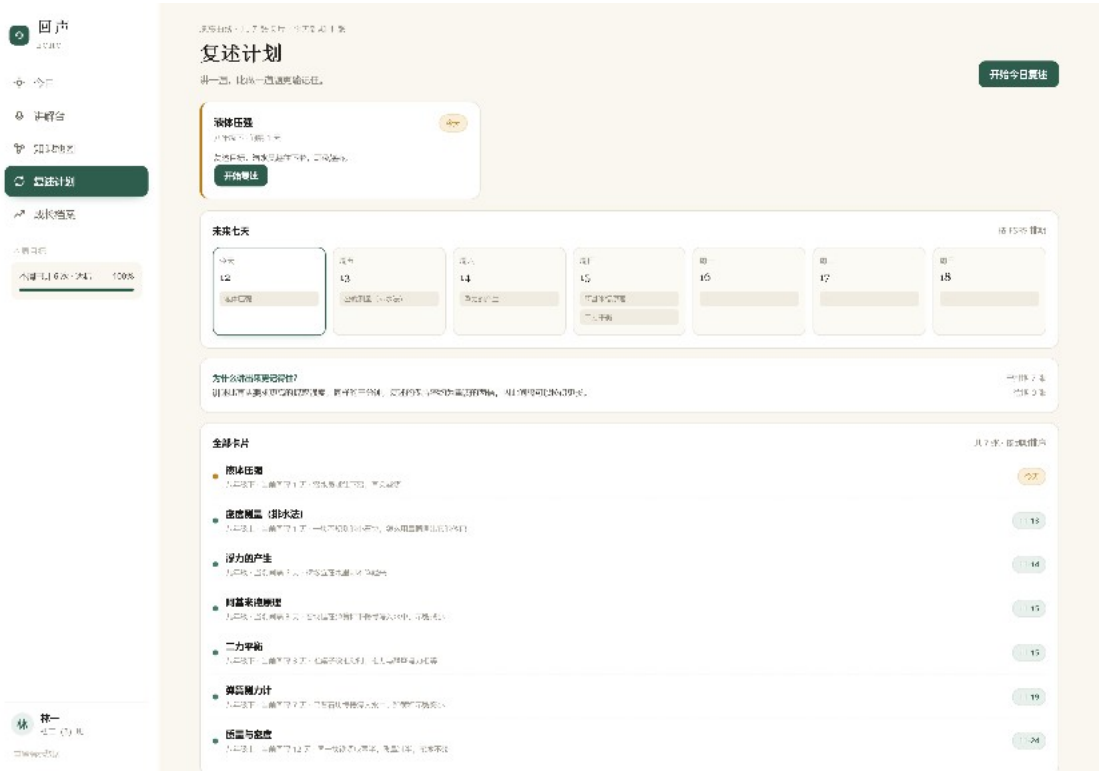


图 15　复述计划实现效果

复述计划把「今天要做什么」放在最上面，写明复述目标而不是只给知识点名字；下方是未来七天与全部卡片，每张卡片都标着当前间隔，让人看得见间隔正在变长。

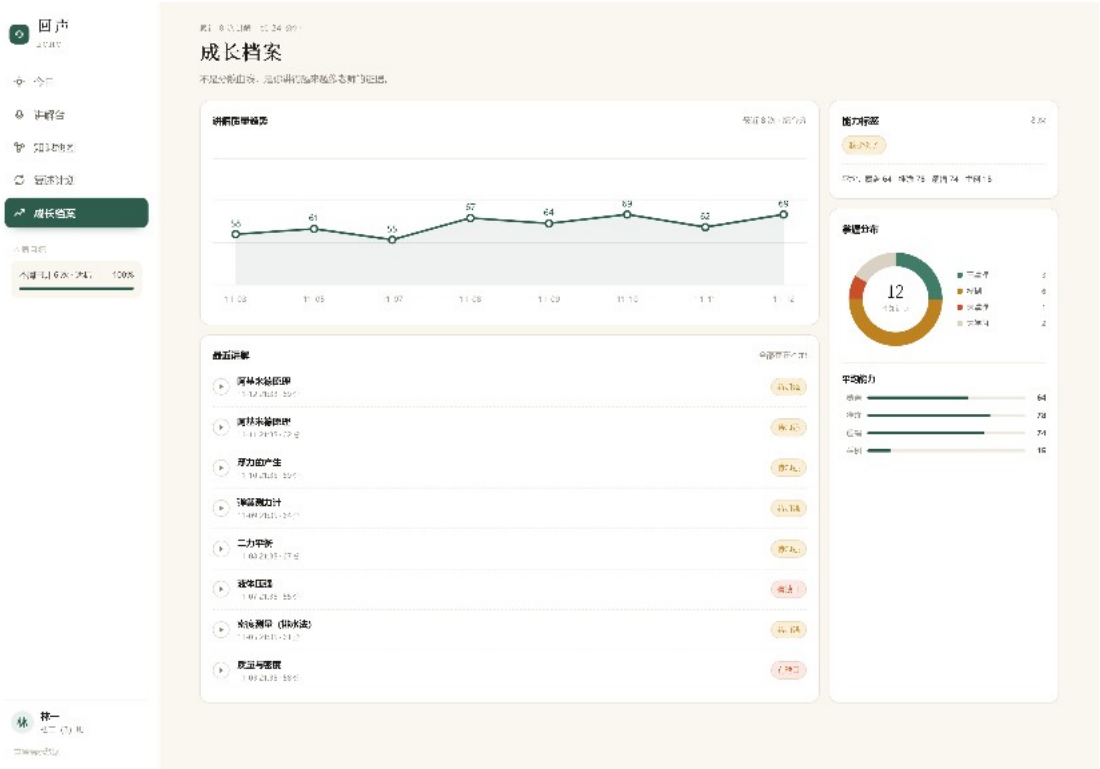


图 16　成长档案实现效果

成长档案的折线记录的是讲解质量而非考试分数，配文是「不是分数曲线，是你讲得越来越像老师的证据」。

6.4 一次完整演示的数据链路

以样例「有缺口的讲解」为例，系统内部实际发生的计算是：8 句话被切成 13 个匹配单元，与 9 条断言构成 13×9 的相似度矩阵，匈牙利算法给出 5 条「讲到位」、1 条「一带而过」、3 条「没提到」，加权覆盖率 64%。同时，触发词命中了迷思 M-17，于是「与深度无关」这条断言被直接判为「讲反了」，不再计入覆盖。

六维评分得到覆盖 64、准确 78、逻辑 74、术语 87、举例 15、流畅 86，加权合成综合分 69。沿图反推两层，根因链为「密度测量（排水法）0.47 → 阿基米德原理」，因为前者的掌握度低、且在依赖路径上离目标最近。该生对阿基米德的掌握度由 0.34 更新为 0.23，并按复习等级 2 生成三天后的复述卡。

这条链路上没有一个数字是预先写死的。换一段讲解、换一个学生，结果就不同。

6.5 已知问题

其一，浏览器语音识别依赖在线服务，离线环境下不可用，因此演示走「文字输入」与「逐步播放示例」两条路径；语音通道保留了接口，联网即可启用。

其二，每个知识点目前只有 5 至 9 条断言，覆盖不了全部讲法，断言库仍需在真实课堂中扩充，这是当前影响覆盖率准确性的最大因素。

其三，多人并发尚未压测。班级场景下四十人同时讲述，SQLite 的写并发与单个进程的吞吐都需要验证，必要时换成 WAL 模式或轻量队列。

七、总结

7.1 创新点小结

第一，范式创新：把 AI 从“判官”变成“学生”，用角色反转激活费曼技巧与学徒效应，这是当前学习类产品中尚未被占据的位置。

第二，评价对象创新：评价的不是答案，而是讲解。这让问题在学生自我感觉良好时就能被发现。

第三，诊断可解释：输出的是连通的根因链，而不是知识点清单；每一条结论都能回指到断言、原话与依赖边。

第四，追问可控：用图谱缺口、探针池与信息增益决定问什么，用约束解码保证不跑偏、不泄题、不超纲，避免了“AI 闲聊式追问”的常见失效。

第五，工程轻量化：25 MB 模型、浏览器语音识别、单文件数据库，无显卡无网络可用，使产品具备真正进入普通教室的条件。

7.2 局限

其一，当前设计只覆盖理科中结构清晰、断言明确的陈述性知识。对作文、历史论述这类开放性表达，断言单元的拆分会变得主观，方法的有效性需要另行验证。

其二，语音识别对方言与专业术语仍不友好，虽然提供了文字输入兜底，但这会削弱“讲出来”的自然感。

其三，评分仍依赖教师校准。系统能指出“哪里没讲到”，但对“讲得好不好”的判断，短期内无法脱离人的参照。

7.3 下一步

近期将完成浮力章节的完整实现与四十人试点，重点验证两件事：根因链的结论是否被教师认可，以及学生在看到报告后是否愿意再讲一遍。中期扩展到力学其余章节，并补

充教师端。远期希望把“讲述”这一模态扩展到更多学科，让“讲一遍”成为和“做一套题”同等自然的学习动作。

回到最初的那句话：讲一遍，才知道自己哪里不会。这个朴素的道理人人都懂，缺的只是一个愿意听、听得懂、还会追问的听众。回声想做的，就是那个听众。